

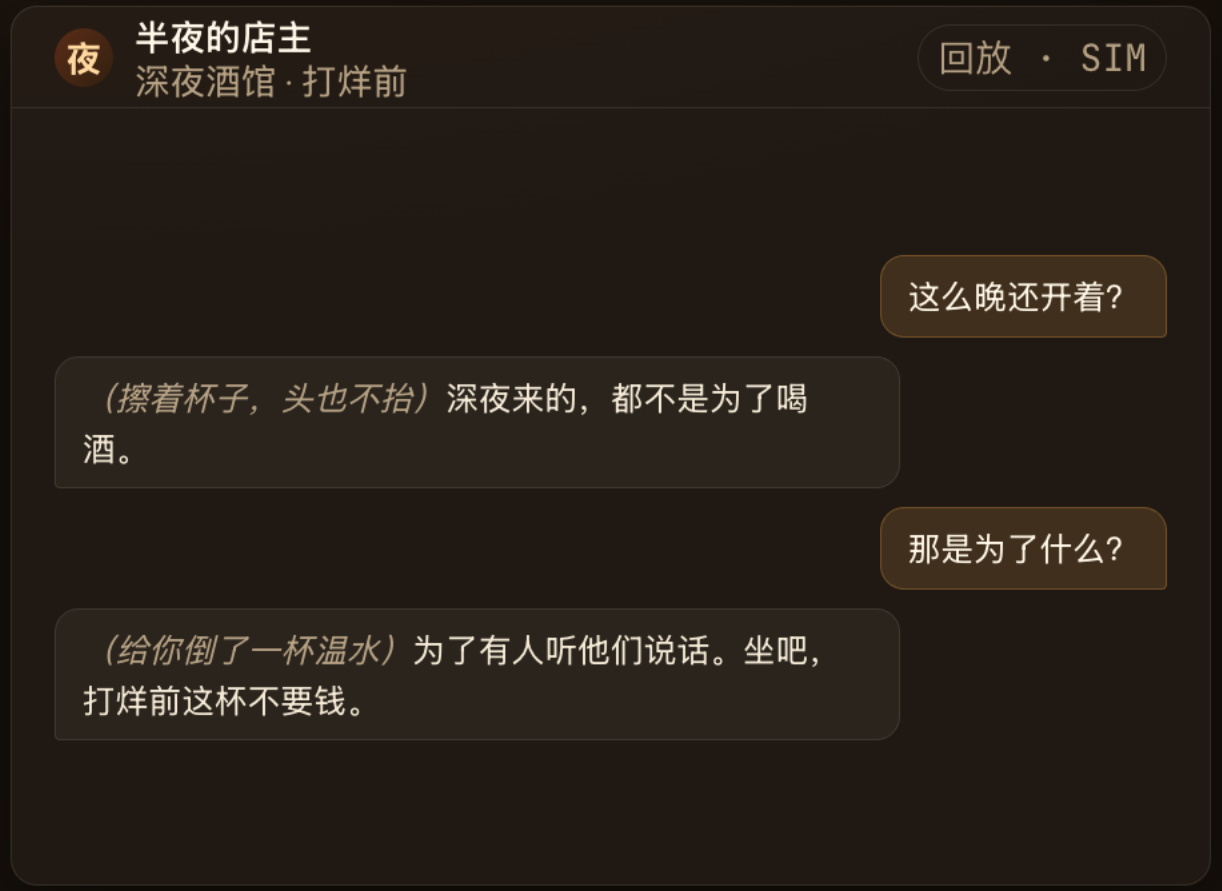
AI 社团 · 分享夜

# 今晚，酒馆开张

SillyTavern：一个通往无数世界的前端

AI 社团 · 2026

# 一场对话






刚才这段对话——是谁在「扮演」？它读过角色设定吗？

# 它只做一件事：预测下一个字

大语言模型 = **文字接龙机器**：给开头，它猜下一个字；猜完一个，再猜下一个。

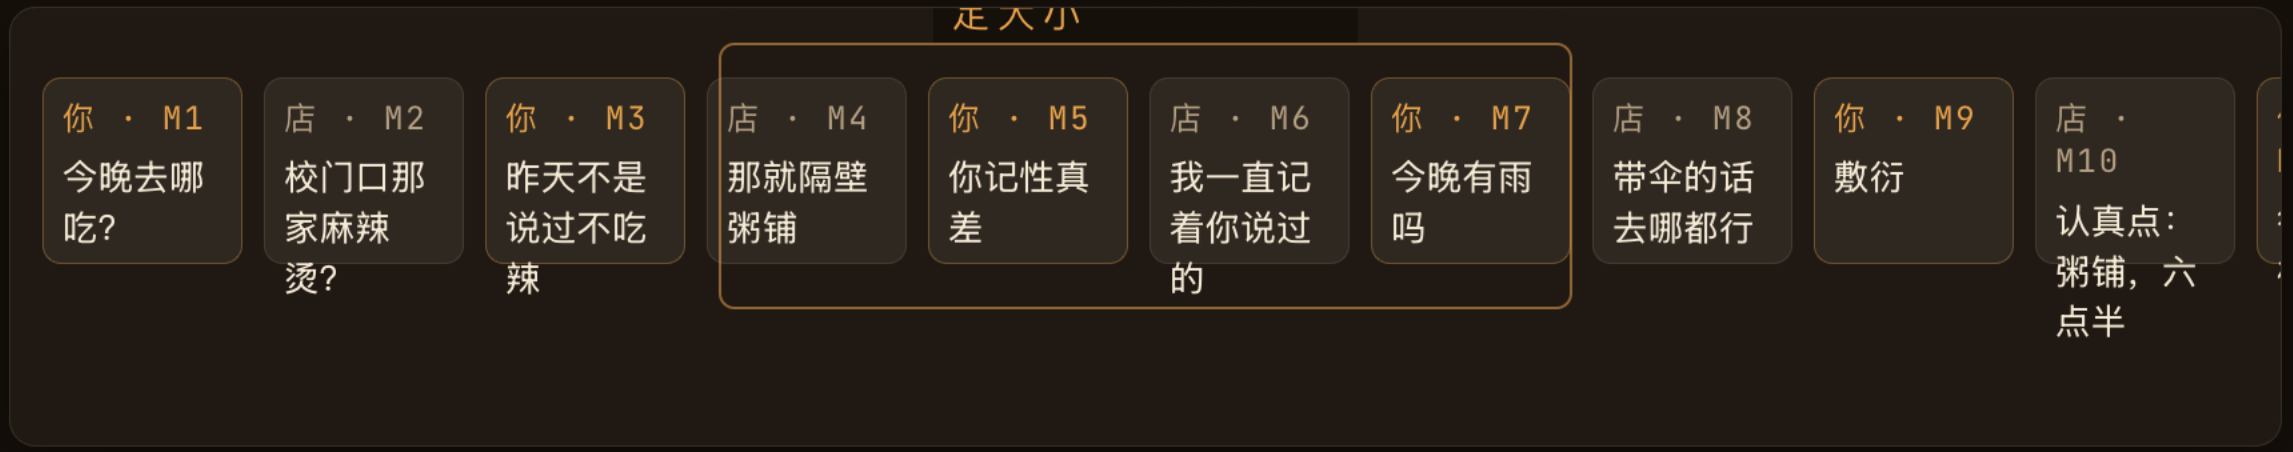
接龙演示 · 逐 TOKEN 生成 SIM

海绵宝宝去蟹堡王上
班，路上遇到了派大星……

所谓**「人设」**，本质上只是喂给它的文字——没有灵魂，只有概率。

# 它没有记忆：上下文窗口

每一轮对话，**全部历史都要重新发一遍**。窗口只有固定大小——装不下时，最早的记忆被挤出。




聊得更多 →

窗口内 **5** 条 · 挤出 **0** 条

# SillyTavern · 为「折腾党」而生

「LLM Frontend for Power Users」

—— 官方给自己的定义。中文圈则叫它：酒馆。

**2023**
从 TavernAI 分叉，社区接管

**2023~2026**
开源社区持续重写 · 插件生态爆发

**v1.19.0 · 2026.09**
AGPL-3.0 · 仍在活跃更新

开源免费 | 高度可定制 | 社区生态庞大

三年周更不停 —— 这项目靠社区活着

# 前端与后端分离：界面 ≠ 智能

### 前端 · 你看到的酒馆

界面、角色卡、聊天记录、插件——全在你自己的设备上

这么晚还开着？

深夜来的，都不是为了喝酒。

那是为了什么？

你按下发送 → 你的**全部上下文**打包发往大脑 → 回复流式回来

### 后端 · 任意一个「大脑」

它只负责接龙。换大脑 = 改一个接口地址

| | |
|---|---|
| DeepSeek | `api.deepseek.com` |
| 本地 Ollama | `localhost:11434` |
| AI Horde | `free · 众包` |

ChatGPT 是捆绑套餐；酒馆把界面拆出来单卖——大脑随你换。

# 万能插头：能接的模型谱系

**云端 API**

质量最好 · 按 token 计费 · 要联网

DeepSeek | GLM | Qwen | Claude | Gemini | OpenRouter…

**本地模型**

断网能玩 · 笔记本跑小模型 · 隐私最强

KoboldCpp | llama.cpp | Ollama

**完全免费**

零成本开箱即用 · 排队共享算力

AI Horde | Pollinations

换模型 = **改一个接口地址**——界面、角色卡、聊天记录全部不动。免费档就能玩全部功能。

# 你的数据在你手里

### 网页服务 · 聊天在别人服务器

记录存在厂商云端，说没就没

导出受限，搬家困难

政策一改，人设全灭

### 酒馆 · 一切都是本地文件

聊天记录 / 角色卡 / 设定 = 你磁盘上的文件

随时备份、分享、搬家

Win / Mac / Linux · 手机浏览器直接访问

**文件即资产** —— 不绑架任何人的数据，所以适合当社团基础设施。

# 诚实的定位：它适合谁

## 适合你，如果——

想**掌控每个细节**：提示词、参数、界面都要自己说了算

想**真的看懂 LLM**：今晚这种解剖，只有开源工具给你看

是**创作者**：跑团 GM、语言陪练、小说共创

## 先别折腾，如果——

只想**开箱即用**：装环境、读文档对你来说 是痛苦而非乐趣

只想要一个**官方 App** 的稳定体验

（更轻的替代：RisuAI 等，也能玩角色卡）

# 角色卡：一张 PNG 的魔法

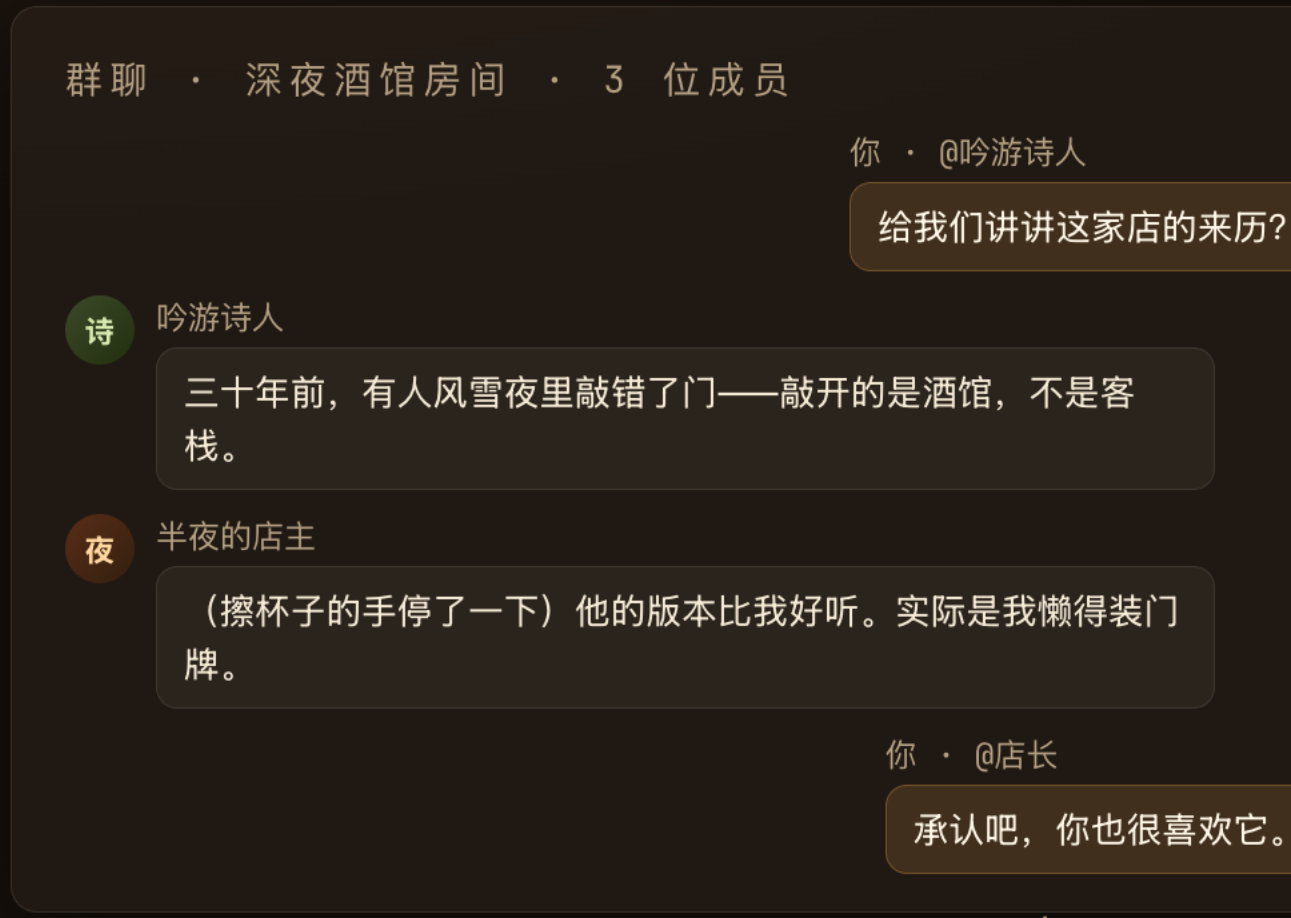



owner_midnight.png · 图片是皮，数据藏在里面

| | |
|---|---|
| name | 半夜的店主 |
| description | 深夜酒馆的店主，慵懒毒舌但心软…… |
| personality | 外冷内热 · 记得每位常客的口味 |
| scenario | 打烊前最后一杯酒的时间 |
| first_mes | 「欢迎光临。想喝点什么？」 |
| mes_example | <START> 示例对话若干轮…… |

拆开看：每个字段都是**提示词模板的一个槽位**。V2/V3 规范互通——社区百万张卡，导入即玩。

# 群聊：让角色同台




还是接龙——只是提示词里写了「**你现在扮演房间里的所有人**」。@谁，谁接话。

# 世界书：会自己出现的设定

世界书 · 比奇堡设定集（3 / 24 条）

**蟹堡王** 关键词：蟹堡王
海绵宝宝工作的地方，招牌蟹黄堡秘方锁在办公室。

**章鱼哥** 关键词：章鱼哥
收银员，厌倦一切，吹竖笛，讨厌两个邻居。

**水母田** 关键词：水母
城外粉色水母成群，抓水母是周末运动。

你

我推门进**蟹堡王**，想找点吃的。

店 · AI

柜台的章鱼哥把订单拍在台面上：「秘方不外卖，堂食等着。」

请求包本次注入：**「蟹堡王」条目**（其余设定沉睡）

设定太多塞不下？**平时睡觉，提到才加载**——记住这个动作，第 17 页给它一个学名。

# 扩展生态：给酒馆装插件

### TTS 语音
角色开口说话，配音随卡切换

### AI 绘图
聊天里直接生成场景与立绘

### 自动翻译
外语角色实时翻成中文

### 聊天总结
旧对话压缩成摘要塞回窗口

### 正则渲染
输出变成状态栏 / 属性面板 / 游戏 UI

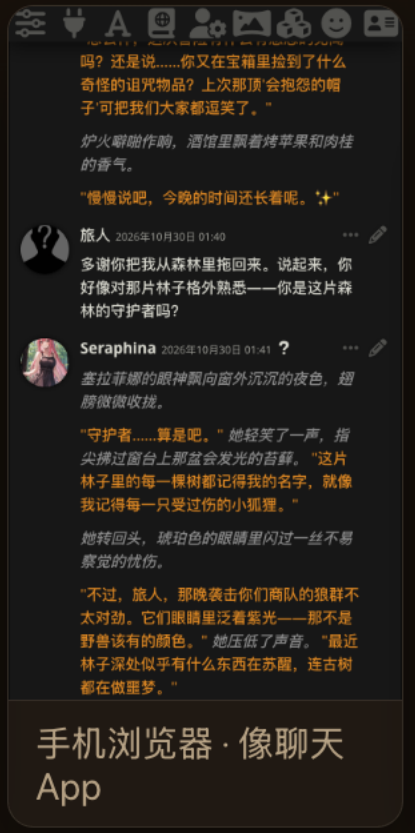
### 用户脚本
自己写 JS 改造每一个环节

所有插件都在同一件事上加料：改写「发出去的字」，或美化「收回来的字」。

# 界面：从极客到手机 App



桌面 · 深色主题（本机实拍）



手机浏览器 · 像聊天 App



正则 + CSS · 消息渲染成游戏 UI





界面是前端 → **皮肤随便换，大脑不受影响**（回扣第 6 页）。体验站里大家自己摸。

# 玩法案例 · 实录三连

跑团 GM　语言陪练　小说共创








不是宣传图，是**我们自己录的**——你们每个人今晚之后都能搭出一样的。

# 解剖一次请求







你按下「发送」的瞬间，这四路内容装进同一包

这一包，就是模型看到的全世界

# 世界书的学名：RAG

STEP 1 · RETRIEVAL

**检索**

关键词命中 → 从设定库里**找回**相关条目

第 12 页：提到「蟹堡王」→ 蟹堡王条目亮起

→

STEP 2 · AUGMENTED GENERATION

**增强生成**

把找到的字**注入请求包**，模型的回答立刻带上设定

注入 → 「这一包，就是模型看到的全世界」多了一块

## 检索增强生成 · RAG

企业客服机器人、知识库助手——底层思想与**世界书一模一样**。简历上可以写：理解 RAG。别笑，是真的。

# 记忆的代价：总结与向量

还记得第 4 页吗——窗口满了。民间最朴素的「长期记忆」补丁，有两条路：

PATCH 1 · SUMMARIZE

## 总结：旧对话压成一段摘要

早期对话整段压缩成一小段记忆塞回窗口——牺牲细节，保住连贯。

36 轮对话 · 约 9,000 字 → 挤爆窗口
压缩后：「两人相识于酒馆，你欠店主一杯酒的债，正在打烊前偿还……」（120 字）

PATCH 2 · EMBEDDINGS

## 向量检索：按语义找回旧片段

把旧消息变成向量；说到相关话题时，最相似的片段自动回窗——像世界书，但按**意思**触发。

你说「那杯酒的债」→ 自动找回 30 轮前的赊账对话

原理你们已经全懂了——剩下只是工程化的名字。

# 上手路径：三条路

最快 · 10 分钟

## 一键整合包

下载 → 解压 → 双击。零命令行，适合先玩起来。

正统 · 5 分钟

## git clone + Node

`git clone` → `npm i` → `node server.js`。更新一行命令，社区推荐姿势。

极客 · Docker

## 自托管

一条 `docker run` 常驻——我们体验站的部署方式，多用户共用。

接模型：填一个 **API 地址 + Key**（DeepSeek 注册即得；或先用免费的 AI Horde）。指南站二维码在最后一页，卡住了社团群里有我们。

# 安全与避坑：三条纪律

纪律 01 · KEY

### API Key = 钱包

别提交到 `GitHub`，别发群里，别贴截图。泄漏 = 别人拿你的钱包刷 API。

纪律 02 · 隐私

### 云端 API 看得到你的全部对话

发出去的字都会过别人服务器——隐私内容想清楚再发。本地模型 = 隐私最强档。

纪律 03 · 分寸

### 内容有护栏，底线要自己守

违法有害内容别碰。社团体验站**有日志**——互联网没有真正 deleted。

不是免责套话，是**真实世界的使用纪律**。

从 玩 到 学

# 今晚你已经理解了——

- 提示词就是一切
- 上下文窗口
- 结构化角色卡
- 关键词触发 = RAG
- 前后端分离

## Q & A

上手指南
三条路 + 模型接入 + FAQ

体验站
扫码即聊 · 官方角色卡已备好



酒馆最好玩的地方，是你玩着玩着，把 LLM 学了。今晚，酒馆永远开张。