今晚，
酒馆开张

SillyTavern，中文圈叫它「酒馆」——一个开源的 AI 角色扮演前端。
一杯酒的时间，零基础玩懂大语言模型，顺手把全部原理带走。

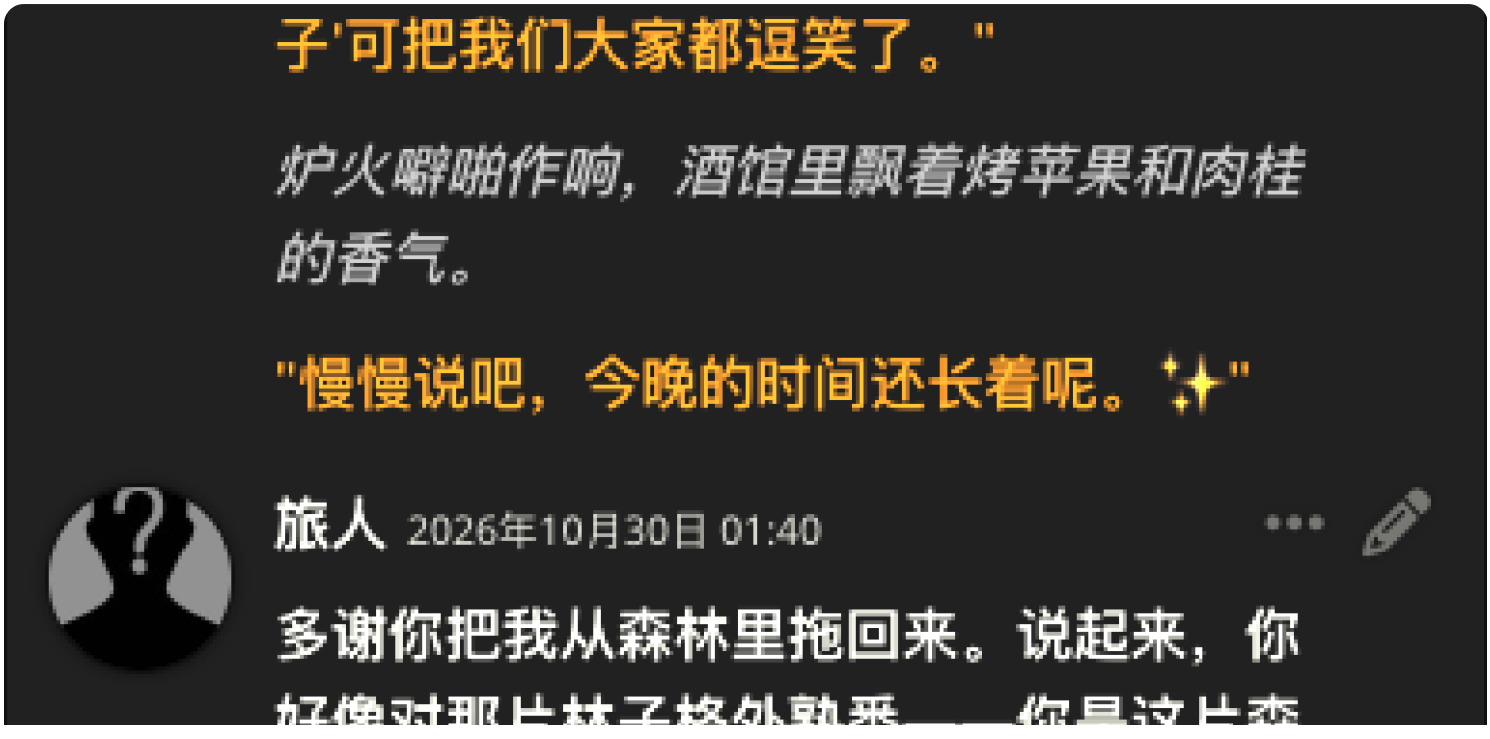
推门而入

序幕 · 先看一场对话

先别解释。先看一段对话——它像不像你手机里的聊天 App？你猜，是谁在「扮演」对面那位？答案可能和你想的不一样。

酒馆老板 准备中

老板有两副嗓子：开场是离线罐头——不花钱、断网也能演；你发一句话，他就去接一颗真大脑，每个字都是此刻生成的。断了网？自动回到罐头，酒馆照常开门。同一副界面，换一颗大脑——这就是前端。





真机实录 · SillyTavern 手机端

想边看边装？上手指南五分钟入门，先看离线回放不用花一分钱。

第一幕 · 接龙机器

大语言模型（LLM）只做一件事：预测下一个字。它不是在「思考」，是在玩一场规模空前的文字接龙。

接龙现场 「海绵宝宝去蟹堡王上」—— **班，路上遇到了派大星……**

逐字生成

上面这句就是这么蹦出来的——每个字都是一个一个猜出来的，猜完一个，再猜下一个。

没有灵魂，只有概率

没有神秘的「自我」。所谓人设，本质上只是喂给它的文字。

它没有记忆

每轮对话，它都把全部历史重新读一遍。忘了不是故障，是物理限制。

上下文窗口

窗口 = 它一次能「看见」的字数上限。后面所有功能，都是在给这扇窗打补丁。

拖一拖那扇窗

它没有记忆

每一句话，都是一次新对话。它看不见你刚刚说过什么，也看不见你们曾经聊过多久。

你对它说下一句话时，它能看到的记忆就只有这一句。

老板，来杯热的。

（擦杯子）今晚想喝点什么？

有什么故事吗？

酒单上没有，你嘴里有。

本次请求的上下文窗口

容量 6 条

你：老板，来杯热的。

老板：（擦杯子）今晚想喝点什么？

你：有什么故事吗？

老板：酒单上没有，你嘴里有。

（空槽位）

（空槽位）

窗口还很宽裕，一切都记得。

教学用了 6 条的小窗；真实模型的窗口动辄十几万字——但挤出即忘，机制一模一样。

第二幕 · 界面与大脑，是分开的

界面 ≠ 智能。

酒馆把界面拆出来单卖：大脑随你换，改一个接口地址就行。



身世

2023 年 2 月从 TavernAI 分叉，社区接管至今：300 多名贡献者、三年多独立开发，官方承诺永远免费开源。当前版本 v1.19.0（2026 年 9 月，AGPL-3.0），仍在活跃更新。

你的数据在你手里

它跑在你自己的电脑上：聊天记录、角色卡、设定全是本地文件。可备份、可分享、可搬家，换电脑打包就走。ChatGPT 是界面和大脑焊死的捆绑套餐；酒馆反过来——大脑随你换，改一个接口地址就行。

它适合谁

为「折腾党」而生：官方给自己的定位是 LLM Frontend for Power Users。想要开箱即用的轻量聊天，RisuAI 之类更合适——门槛本身就是今晚要拆掉的东西。

GitHub 仓库

适合你，如果——

- 你想掌控细节：提示词、参数、记忆策略全可调
- 你想真的理解 LLM：每个功能都是一层原理
- 你是创作者、跑团党、语言陪练党

先别折腾，如果——

- 只想开箱即用聊个天（轻量替代更合适）
- 不愿意花 10 分钟做一次安装
- 期待它「自己什么都会」——它只是个前端

万能插头：能接的大脑

- **云端 API** DeepSeek / GLM / Qwen / Claude / Gemini / OpenRouter……质量最好，按量付费，DeepSeek 一次对话不到一分钱
- **本地模型** KoboldCpp / llama.cpp / Ollama，笔记本就能跑小模型——断网也能玩，宿舍里就行
- **完全免费** AI Horde 众包算力、Pollinations——开箱即用，零成本体验全部功能

第三幕 · 今晚的菜单

酒馆能玩什么？按菜单点。每一道都是同一个原理的变体：把文字喂进去，把角色请出来。

桌上菜

五道 · 全部本地



角色卡 · 一张 PNG 的魔法

结构化提示词

名字、描述、性格、场景、示例对话、首条消息——图片是皮，藏在里面的 JSON 是魂。V2/V3 规范互通，社区百万张卡直接导入就能玩。



群聊 · 让角色同台

一个模型演一台戏

多个角色头像互相接话，你 @ 谁谁说话。原理没变：提示词里写了「你现在扮演房间里所有人」。



世界书 · 会自己出现的设定

RAG 的种子

设定库平时睡觉，聊天里提到「蟹堡王」，那条设定才醒来、飞进请求包。记住这个动作，第四幕给它一个学名。



插件货架 · 给酒馆装插件

一切皆是文字加工

TTS 语音、AI 绘图、自动翻译、总结记忆、正则渲染成状态栏……全在改写「发出去的文字」、美化「收回来的文字」。



界面 · 从极客到手机 App

主题随便换

桌面深色主题、手机竖屏像聊天 App、正则 + CSS 能把消息渲染成游戏 UI。界面是前端——所以皮肤随便换，大脑不受影响。

实拍实录

点一道菜，换一段实录 · 本机录制



跑团 GM

骰子 · 剧情推进

掷骰判定、状态栏、剧情推进，一个人也能开团。



语言陪练

纠错 · 情景对话

顺手纠错、代入情景，比背单词软件有耐心得多。



小说共创

给开头 · AI 接龙

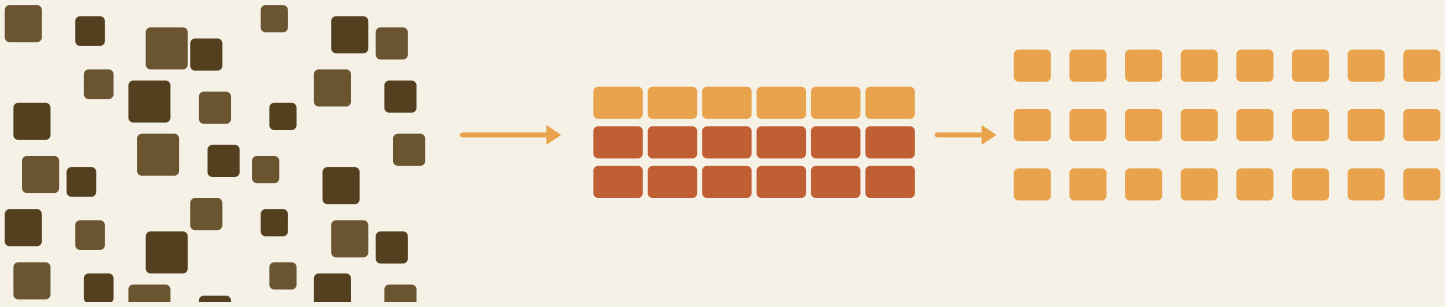
你起个头，它接龙改写——接龙机器的本职工作。

跑团 GM · 实录

不是宣传图，是我们自己录的。今晚之后，你们每个人都能搭出一模一样的。

第四幕 · 解剖一次请求

你在酒馆里按下「发送」的那几秒，其实发生了什么。左边的散料，被装配成一包，发往大脑——回复再逐字流回来。



收集

角色卡、世界书（提到「酒馆」才醒来的那条）、预设（社区调好的「说话风格」参数包）、聊天记录——四种散料。

装配

按真实拼装顺序压成一包。**这一包，就是模型看到的全世界。**

回流

大脑逐字接龙，回复流回聊天窗口。你看到「它在思考」，其实它在猜下一个字。序幕的问题到这里也揭晓了：**没有谁在「扮演」老板——只有一包字，和一台读完它、猜下一个字的接龙机器。**

这个动作，有个学名

检索增强生成（RAG）：企业客服机器人、知识库助手，底层思想和世界书一模一样。你在酒馆里玩懂的这个机制，就是工业界 RAG 的最小模型。

补丁一 · 总结

窗口又满了？把旧对话压缩成一段摘要塞回去——细节没了，脉络还在。

补丁二 · 向量检索

按语义（而不是关键词）把相关的旧片段找回来，重新塞进窗口。ST 的记忆扩展和内置的 Data Bank，就是这两条土方的实现。

第五幕 · 今晚就开张

把酒馆装进你的电脑。

选一条路：

照着指南走

一键整合包——下载、解压、双击。三步，五分钟内进门。适合第一次接触、电脑里没有命令行的同学。

模型接入 = 在设置里填一个 API 地址和 Key（DeepSeek 注册即得）。三条路殊途同归：界面、角色卡、聊天记录完全一样。卡住了，社团群里有我们。

手把手图文 · 上手指南

从下载到第一句对话，每一步带截图。

tavern.phuyu.cloud/guide

前往 ↗



上桌之前 · 三条纪律

- **API Key = 钱包**

  别提交到 GitHub，别发群里。泄漏了 = 别人拿你的钱包刷 API。

- **云端 API 看得到你的全部对话**

  发出去的字都经过对方服务器。隐私内容，想清楚再发。

- **内容有分寸**

  模型有护栏，违法有害内容别碰。体验站会记日志——互联网没有真正「删除」。

散场之前 · 常见问题

手机能玩吗? ×

能。酒馆装在电脑上，手机浏览器访问同一局域网地址即可，界面本身就是手机优先设计。整合包也有手机端方案（Termux），但推荐从电脑开始。

要花多少钱? +

和 Character.AI 有什么区别? +

Key 泄漏了怎么办? +

卡住了找谁? +

需要会编程吗? +

它一本正经地胡说八道怎么办? +

角色卡去哪找? +

散场前，查一眼战利品

一杯酒的时间，你其实已经把这门课修完了：

◊ 提示词　◊ 上下文窗口　◊ 检索增强生成　◊ 前后端分离　◊ Token · 令牌

今晚，酒馆永远开张。

酒馆最好玩的地方不是它多能玩，
而是你玩着玩着，把 LLM 学了。

上手指南 · 扫码即达

tavern.phuyu.cloud/guide



今晚的页面

序幕 · 对话

第一幕 · 大脑

第二幕 · 酒馆

第三幕 · 菜单

第四幕 · 解剖

第五幕 · 上手

出门右转

上手指南

SillyTavern · GitHub

SillyTavern · 中文文档

AI Horde · 免费算力

体验站 · 筹备中

关于素材

插画由 AI 生成；实录为本机 SillyTavern 录制；界面截图为真实软件。

SillyTavern 采用 AGPL-3.0 开源协议。

晋ICP备2025069595号-2

回到顶部